OceanBase 论文精读笔记：707 万 tpmC 的分布式关系数据库

论文信息

论文：OceanBase: A 707 Million tpmC Distributed Relational Database System，PVLDB 2022。
作者来自蚂蚁集团 OceanBase 团队。TPC-C 是 OLTP 基准，衡量每分钟新订单事务数（tpmC）。
该论文报告在 TPC-C 上达到 7.07 亿 tpmC，所有业务数据存放在同一套分布式数据库中。
关键结论：单机数据库的扩展上限可以通过「共享存储无关的多副本 Paxos 组 + 分区」突破。

架构要点

OceanBase 采用 shared-nothing 架构，每个分区（partition）是一个 Paxos 组，通常三副本。
副本之间用 Paxos 协议同步 redo 日志，多数派持久化即可对外提供服务，保证 RPO=0。
多副本中的 Leader 处理读写，Follower 参与投票与日志持久化；Leader 故障时自动重新选主。
存储层使用 LSM-Tree 风格的基线数据 + 增量 memtable，合并（major freeze）把增量转成 SSTable。

事务与一致性

分布式事务使用两阶段提交（2PC）加全局时间戳服务（GTS），保证快照读的一致性。
GTS
为每个事务分配提交版本号，读操作按照版本号获取一致性快照，实现多版本并发控制（MVCC）。
跨机房的强一致通过 Paxos 多数派实现；同城三机房部署时，任一机房故障不丢数据。
租户（tenant）是资源隔离单位，多个租户共享一套集群，CPU 与内存按租户配额调度。

对学习的启发

把「共识协议 + 日志复制 +
多版本」串起来看，才能理解分布式数据库为什么能同时做到高可用与强一致。
benchmark 数字的解读要看前提：tpmC、响应时间约束、数据量与硬件配置必须一起报告。
复习时优先掌握三个因果链：Paxos 多数派 -> 不丢数据；GTS 版本号 -> 快照隔离；LSM 合并 ->
写放大。